

– תרגול מספר 5


מבוא ללמידה מודרכת (Supervised)

KNN-1


סימונים ותקציר תאוריה

- $D = \{x_i, y_i\}_{i=1}^n$ - דוגמאות (דגימות - samples) בלתי תלויות של X עם פרדיקציה ידועה Y .
- X - מרחב הקלט. $x \in X$.
- המטרה היא ללמוד מיפוי (פונקציה, אלגוריתם) f אשר מאפשר חישוב פלט מתאים $y = f(x)$ לכל קלט אפשרי $x \in X$. למיפוי הנלמד f נקרא "פונקציית החיזוי" או "חזאי".
- \mathcal{F} - מרחב המיפויים האפשריים. למשל – מיפויים ליניאריים $\mathcal{F} = \{f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b \mid \forall \mathbf{w} \in \mathbb{R}^d, b \in \mathbb{R}\}$.
- מרחב הפלט תלוי במשימה, נבחין בין שתי משימות שונות:
 1. רגרסיה – Regression : הפלט y הינו מספר ממשי.
 2. סיווג – Classification : הפלט y הינו משתנה קטגורי בעל מספר סופי של ערכים $y = \{1, \dots, K\}$. ערכי y נקראים גם מחלקות.


Regression



Regression




Regression




- ההבדל בין קירוב לחיזוי


Regression



Regression



Regression



בחירת סדר המודל

- למשל עבור מיפויים ליניאריים $\mathcal{F} = \{f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b \mid \forall \mathbf{w} \in \mathbb{R}^d, b \in \mathbb{R}\}$ בחירת הגודל $d + 1$.
- סדר המודל (למשל, מספר הפרמטרים במודל פרמטרי) קובע, כעיקרון, את גודל קבוצת הפונקציות הכלולות במודל. ככל שסדר המודל גדול יותר, כך קבוצה זו עשירה יותר, ומכילה פונקציות מסובכות יותר.
- סוגיה יסודית בבחירת סדר המודל הינה הניגוד הבא:
 - מודל פשוט מדי (בעל סדר נמוך) לא יאפשר תיאור מדויק של הקשר ה"אמיתי" בין הקלט לפלט.
 - מודל מסובך מדי (בעל סדר גבוה) הוא בעל מספר גדול של דרגות חופש, ולפיכך עלול לדרוש מספר רב של דוגמאות על מנת לבצע הכללה סבירה.

בחירת סדר המודל

פונקציית סיכון (risk):

$$R(\hat{f}) = E_{(x,y) \sim p_{X,Y}}(\ell(\hat{f}(x), y))$$

פונקציית סיכון אמפירית:

$$\hat{R}(\hat{f}) = \frac{1}{N} \sum_{ii} \ell(\hat{f}(x_i), y_i)$$

כאשר, ℓ - פונקציית מחיר כלשהי.
למשל:

$$\ell(\hat{f}(x), y) = \begin{cases} 0 & \hat{f}(x) = y \\ 1 & otherwise \end{cases}$$

$$\ell(\hat{f}(x), y) = (\hat{f}(x) - y)^2$$

בחירת סדר המודל - Bias-Variance Tradeoff

- פרוק השגיאה:

$$R(\hat{f}) = E_{app}(F) + E_{est}(\hat{f}, F)$$

- כאשר:

$$E_{app}(F) = \min_{f \in F} R(f) \triangleq R(f^*), \text{ with } f^* \triangleq \operatorname{argmin}_{f \in F} R(f)$$

$$E_{est}(\hat{f}, F) = R(\hat{f}) - R(f^*)$$

F – מודל , משפחת היפותזות

- $E_{app}(F)$ היא שגיאת הקירוב (approximation error), הנקראת גם ההטיה (bias). היא מציינת את הסיכון המינימלי שחזאי כלשהו מתוך המודל F יכול להשיג. גודל זה הינו דטרמיניסטי ואינו תלוי בסדרת הלימוד.
- $E_{est}(\hat{f}, F)$ היא שגיאת השערוך (estimation error). גודל זה הינו הפרש הסיכון עבור החזאי האופטימאלי מתוך המודל – דהיינו f^* לבין החזאי שנבחר על ידי אלגוריתם הלימוד, דהיינו $\hat{f} = \hat{f}(D)$.

בחירת סדר המודל - Bias-Variance Tradeoff

• פרוק השגיאה:

$$R(\hat{f}) = E_{\text{app}}(F) + E_{\text{est}}(\hat{f}, F)$$


• כאשר:

$$E_{\text{app}}(F) = \min_{f \in F} R(f) \triangleq L(f^*), \text{ with } f^* \triangleq \operatorname{argmin}_{f \in F} R(f)$$

$$E_{\text{est}}(\hat{f}, F) = R(\hat{f}) - R(f^*)$$

Bias גבוה	מודל פשוט מדי (בעל סדר נמוך) לא יאפשר תיאור מדויק של הקשר ה"אמיתי" בין הקלט לפלט.	$E_{\text{app}}(F)$ היא שגיאת הקירוב (approximation error), הנקראת גם ההטיה (bias). היא מציינת את הסיכון המינימלי שחזאי <u>כלשהו</u> מתוך המודל F יכול להשיג.
Variance גבוה	מודל מסובך מדי (בעל סדר גבוה) הוא בעל מספר גדול של דרגות חופש, ולפיכך עלול לדרוש מספר רב של דוגמאות על מנת לבצע הכללה סבירה.	$E_{\text{est}}(\hat{f}, F)$ היא שגיאת השערוך (estimation error). גודל זה הינו הפרש הסיכון עבור החזאי האופטימאלי מתוך המודל – דהיינו f^* לבין החזאי שנבחר על ידי אלגוריתם הלימוד, דהיינו $\hat{f} = \hat{f}(D)$.

Regression



$E_{app}(F)$ היא שגיאת הקירוב (approximation error), מציינת את הסיכון המינימלי שחזאי כלשהו מתוך המודל F יכול להשיג.

מודל פשוט מדי (בעל סדר נמוך) לא יאפשר תיאור מדויק של הקשר ה"אמיתי" בין הקלט לפלט.


Bias גבוה

$E_{est}(\hat{f}, F)$ היא שגיאת השערוך (estimation error). גודל זה הינו הפרש הסיכון עבור החזאי האופטימאלי מתוך המודל לבין החזאי שנבחר על ידי אלגוריתם הלימוד, דהיינו $\hat{f} = \hat{f}(D)$.

מודל מסובך מדי (בעל סדר גבוה) הוא בעל מספר גדול של דרגות חופש, ולפיכך עלול לדרוש מספר רב של דוגמאות על מנת לבצע הכללה סבירה.

Variance גבוה

Regression



$E_{app}(F)$ היא שגיאת הקירוב (approximation error), מציינת את הסיכון המינימלי שחזאי כלשהו מתוך המודל F יכול להשיג.

מודל פשוט מדי (בעל סדר נמוך) לא יאפשר תיאור מדויק של הקשר ה"אמיתי" בין הקלט לפלט.



Bias גבוה

$E_{est}(\hat{f}, F)$ היא שגיאת השערוך (estimation error). גודל זה הינו הפרש הסיכון עבור החזאי האופטימאלי מתוך המודל לבין החזאי שנבחר על ידי אלגוריתם הלימוד, דהיינו $\hat{f} = \hat{f}(D)$.

מודל מסובך מדי (בעל סדר גבוה) הוא בעל מספר גדול של דרגות חופש, ולפיכך עלול לדרוש מספר רב של דוגמאות על מנת לבצע הכללה סבירה.

Variance גבוה


Bias-Variance Tradeoff




סימונים ותקציר תאוריה

- $D = \{x_i, y_i\}_{i=1}^n$ - דוגמאות (דגימות - samples) בלתי תלויות של X עם פרדיקציה ידועה Y .
- X - מרחב הקלט. $x \in X$.
- המטרה היא ללמוד מיפוי (פונקציה, אלגוריתם) f אשר מאפשר חישוב פלט מתאים $y = f(x)$ לכל קלט אפשרי $x \in X$. למיפוי הנלמד f נקרא "פונקציית החיזוי" או "חזאי".
- \mathcal{F} - מרחב המיפויים האפשריים. למשל – מיפויים ליניאריים $\mathcal{F} = \{f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b \mid \forall \mathbf{w} \in \mathbb{R}^d, b \in \mathbb{R}\}$.
- מרחב הפלט תלוי במשימה. נבחין בין שתי משימות שונות:
 1. רגרסיה – Regression : הפלט y הינו מספר ממשי.
 2. סיווג – Classification : הפלט y הינו משתנה קטגורי בעל מספר סופי של ערכים $y = \{1, \dots, K\}$. ערכי y נקראים גם מחלקות.


Classification




Classification



Classification



Classification



תהליך הלימוד (ולידציה)

• נחלק את ה-Data שיש לנו לשלוש קבוצות:


1. Training set (סט אימון) – סט דוגמאות מתויג $D = \{x_i, y_i\}_{i=1}^n$ שבאמצעותו האלגוריתם לומד.

2. Validation set (סט אימות) – סט דוגמאות מתויג $D = \{x_i, y_i\}_{i=1}^n$ שבאמצעותו נעריך את טיבם של המודלים על מנת לבחור ביניהם.

3. Test set (סט בוחן) – סט דוגמאות מתויג $D = \{x_i, y_i\}_{i=1}^n$ שבאמצעותו נעריך את ביצועי המודל הסופי שבחרנו.

▪ הערה: השימוש בסט זה הינו השלב האחרון בתהליך הלמידה, ואין להשתמש בו כדי להעריך את ביצועי המודל במהלך הלימוד.

Regression



K-fold Cross-Validation

- במקרים בהם ה-Data הניתן לנו הוא מוגבל, לא נרצה לבזבז Data על ידי הקצאתו ל-Validation Set. שיטה זו מאפשרת לקבל הערכה לשגיאת שערור.

input : $D = \{x_i, y_i\}_{i=1}^n$, integer k , learning algorithm A, model M

1. Create k data partitions: D_1, \dots, D_k ,

$$\text{s.t. } \bigcap_{j=1 \dots k} D_j = \phi, \quad \bigcup_{j=1 \dots k} D_j = D, \quad \forall j, l \quad |D_j| \approx |D_l|$$

2. For $j = 1, \dots, k$


2.1 Fit model M by algorithm A with data $\{D \setminus D_j\}$

2.2 Calculate $\hat{R}_n^{(j)}(M)$

3. Return $\hat{R}_n = \frac{1}{k} \sum_{j=1 \dots k} \hat{R}_n^{(j)}$

K-fold Cross-Validation

Who is your favorite x men character?



K-fold Cross-Validation

input : $D = \{x_i, y_i\}_{i=1}^n$, integer k , learning algorithm A, model M

1. Create k data partitions: D_1, \dots, D_k ,

$$\text{s.t. } \bigcap_{j=1 \dots k} D_j = \phi, \quad \bigcup_{j=1 \dots k} D_j = D, \quad \forall j, l \quad |D_j| \approx |D_l|$$

2. For $j = 1, \dots, k$

2.1 Fit model M by algorithm A with data $\{D \setminus D_j\}$


2.2 Calculate $\hat{R}_n^{(j)}(M)$

3. Return $\hat{R}_n = \frac{1}{k} \sum_{j=1 \dots k} \hat{R}_n^{(j)}$

Who is your favorite x men character?

$k = 2$

● Wolverine
● Storm



K-fold Cross-Validation

input : $D = \{x_i, y_i\}_{i=1}^n$, integer k , learning algorithm A, model M

1. Create k data partitions: D_1, \dots, D_k ,


$$\text{s.t. } \bigcap_{j=1 \dots k} D_j = \phi, \quad \bigcup_{j=1 \dots k} D_j = D, \quad \forall j, l \mid |D_j| \approx |D_l|$$

2. For $j = 1, \dots, k$

2.1 Fit model M by algorithm A with data $\{D \setminus D_j\}$

2.2 Calculate $\hat{R}_n^{(j)}(M)$

3. Return $\hat{R}_n = \frac{1}{k} \sum_{j=1 \dots k} \hat{R}_n^{(j)}$



K-fold Cross-Validation

input : $D = \{x_i, y_i\}_{i=1}^n$, integer k , learning algorithm A, model M

1. Create k data partitions: D_1, \dots, D_k ,


$$\text{s.t. } \bigcap_{j=1 \dots k} D_j = \phi, \quad \bigcup_{j=1 \dots k} D_j = D, \quad \forall j, l \mid |D_j| \approx |D_l|$$

2. For $j = 1, \dots, k$

2.1 Fit model M by algorithm A with data $\{D \setminus D_j\}$

2.2 Calculate $\hat{R}_n^{(j)}(M)$

3. Return $\hat{R}_n = \frac{1}{k} \sum_{j=1 \dots k} \hat{R}_n^{(j)}$



K-fold Cross-Validation

input : $D = \{x_i, y_i\}_{i=1}^n$, integer k , learning algorithm A, model M

1. Create k data partitions: D_1, \dots, D_k ,


$$\text{s.t. } \bigcap_{j=1 \dots k} D_j = \phi, \quad \bigcup_{j=1 \dots k} D_j = D, \quad \forall j, l \mid |D_j| \approx |D_l|$$

2. For $j = 1, \dots, k$

2.1 Fit model M by algorithm A with data $\{D \setminus D_j\}$

2.2 Calculate $\hat{R}_n^{(j)}(M)$

3. Return $\hat{R}_n = \frac{1}{k} \sum_{j=1 \dots k} \hat{R}_n^{(j)}$



K-fold Cross-Validation

input : $D = \{x_i, y_i\}_{i=1}^n$, integer k , learning algorithm A, model M

1. Create k data partitions: D_1, \dots, D_k ,


$$\text{s.t. } \bigcap_{j=1 \dots k} D_j = \phi, \quad \bigcup_{j=1 \dots k} D_j = D, \quad \forall j, l \mid |D_j| \approx |D_l|$$

2. For $j = 1, \dots, k$

2.1 Fit model M by algorithm A with data $\{D \setminus D_j\}$

2.2 Calculate $\hat{R}_n^{(j)}(M)$

3. Return $\hat{R}_n = \frac{1}{k} \sum_{j=1 \dots k} \hat{R}_n^{(j)}$



K-fold Cross-Validation

input : $D = \{x_i, y_i\}_{i=1}^n$, integer k , learning algorithm A, model M

1. Create k data partitions: D_1, \dots, D_k ,


$$\text{s.t. } \bigcap_{j=1 \dots k} D_j = \phi, \quad \bigcup_{j=1 \dots k} D_j = D, \quad \forall j, l \mid |D_j| \approx |D_l|$$

2. For $j = 1, \dots, k$

2.1 Fit model M by algorithm A with data $\{D \setminus D_j\}$

2.2 Calculate $\hat{R}_n^{(j)}(M)$

3. Return $\hat{R}_n = \frac{1}{k} \sum_{j=1 \dots k} \hat{R}_n^{(j)}$



K-fold Cross-Validation

input : $D = \{x_i, y_i\}_{i=1}^n$, integer k , learning algorithm A, model M

1. Create k data partitions: D_1, \dots, D_k ,

$$\text{s.t. } \bigcap_{j=1 \dots k} D_j = \phi, \quad \bigcup_{j=1 \dots k} D_j = D, \quad \forall j, l \mid |D_j| \approx |D_l|$$

2. For $j = 1, \dots, k$

2.1 Fit model M by algorithm A with data $\{D \setminus D_j\}$

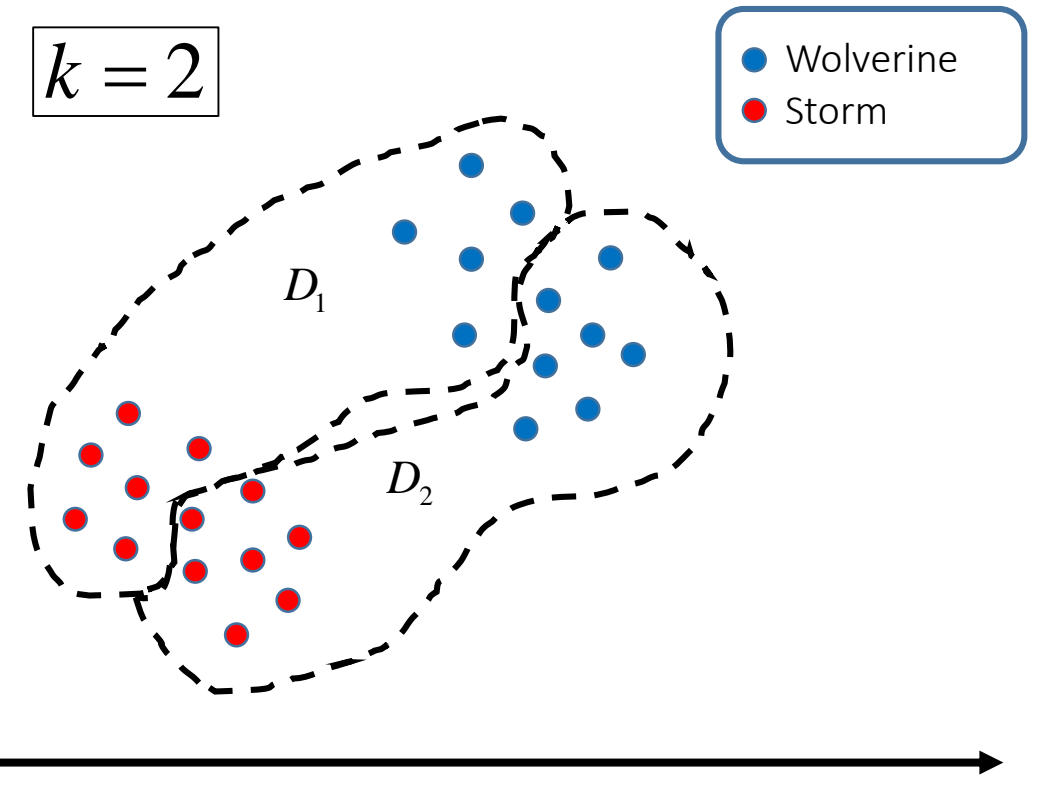
2.2 Calculate $\hat{R}_n^{(j)}(M)$

3. Return $\hat{R}_n = \frac{1}{k} \sum_{j=1 \dots k} \hat{R}_n^{(j)}$

$$\hat{R}_n = 0$$

Who is your favorite x men character?

$$k = 2$$



K-fold Cross-Validation

input : $D = \{x_i, y_i\}_{i=1}^n$, integer k , learning algorithm A, model M

1. Create k data partitions: D_1, \dots, D_k ,

$$\text{s.t. } \bigcap_{j=1 \dots k} D_j = \phi, \quad \bigcup_{j=1 \dots k} D_j = D, \quad \forall j, l \mid |D_j| \approx |D_l|$$

2. For $j = 1, \dots, k$

2.1 Fit model M by algorithm A with data $\{D \setminus D_j\}$

2.2 Calculate $\hat{R}_n^{(j)}(M)$


3. Return $\hat{R}_n = \frac{1}{k} \sum_{j=1 \dots k} \hat{R}_n^{(j)}$

$$\hat{R}_n = 0$$

Who is your favorite x men character?

$$k = 2$$

● Wolverine
● Storm



K-fold Cross-Validation

input : $D = \{x_i, y_i\}_{i=1}^n$, integer k , learning algorithm A, model M

1. Create k data partitions: D_1, \dots, D_k ,

$$\text{s.t. } \bigcap_{j=1 \dots k} D_j = \phi, \quad \bigcup_{j=1 \dots k} D_j = D, \quad \forall j, l \mid |D_j| \approx |D_l|$$


2. For $j = 1, \dots, k$

2.1 Fit model M by algorithm A with data $\{D \setminus D_j\}$


2.2 Calculate $\hat{R}_n^{(j)}(M)$

3. Return $\hat{R}_n = \frac{1}{k} \sum_{j=1 \dots k} \hat{R}_n^{(j)}$

* Repeated cross-validation



סיווג בעזרת אלגוריתם K-NN (k Nearest Neighbours)



1. מצא את K השכנים הקרובים ביותר לנקודה החדשה.

2. מצא לאיזו קבוצה שייכים רוב השכנים. הנקודה החדשה שייכת לקבוצה זו.

1. במקרה של שוויון בשלב 2, השווה סכום מרחקים.

הנקודה החדשה שייכת לקבוצה בעלת הסכום המינימלי.

1. במקרה של שוויון בשלב 2.1, בחר אקראית.

תרגיל 1

ננסה לאפיין האם אבטיח מתוק או חמוץ על פי ההד בהקשה עליהם והקוטר שלהם.

נסמן: R – רדיוס, E – הד

יש לנו את המדידות האלו מהעבר-

Sweet: $(R, E) = (8,1), (5,2), (7,3), (8,5)$

Sour: $(R, E) = (10,2), (6,4), (11,4)$

הסטודנט מחזיק בידו האבטיח בעל המאפיינים $(R, E) = (8,3)$.


האם סביר שהאבטיח מתוק או חמוץ?

1. בדקו את תוצאות ה-classification עבור k-nearest neighbors, כאשר $K=1,3$.

2. בצע Cross Validation להערכת טיב המודל, עבור $K=1,3$ ו-7 קבוצות

(Leave-one-out Cross Validation). באיזה מסווג נבחר?

3. מה יקרה אם נבחר את k להיות בגודל ה-dataset.




תרגיל 1 - פתרון

1. בדקו את תוצאות ה-classification עבור k-nearest neighbors, כאשר $K=1,3$.

פתרון: עבור $K = 1$:

- Sweet
- Sour

$$\hat{y} = \textit{sweet}$$



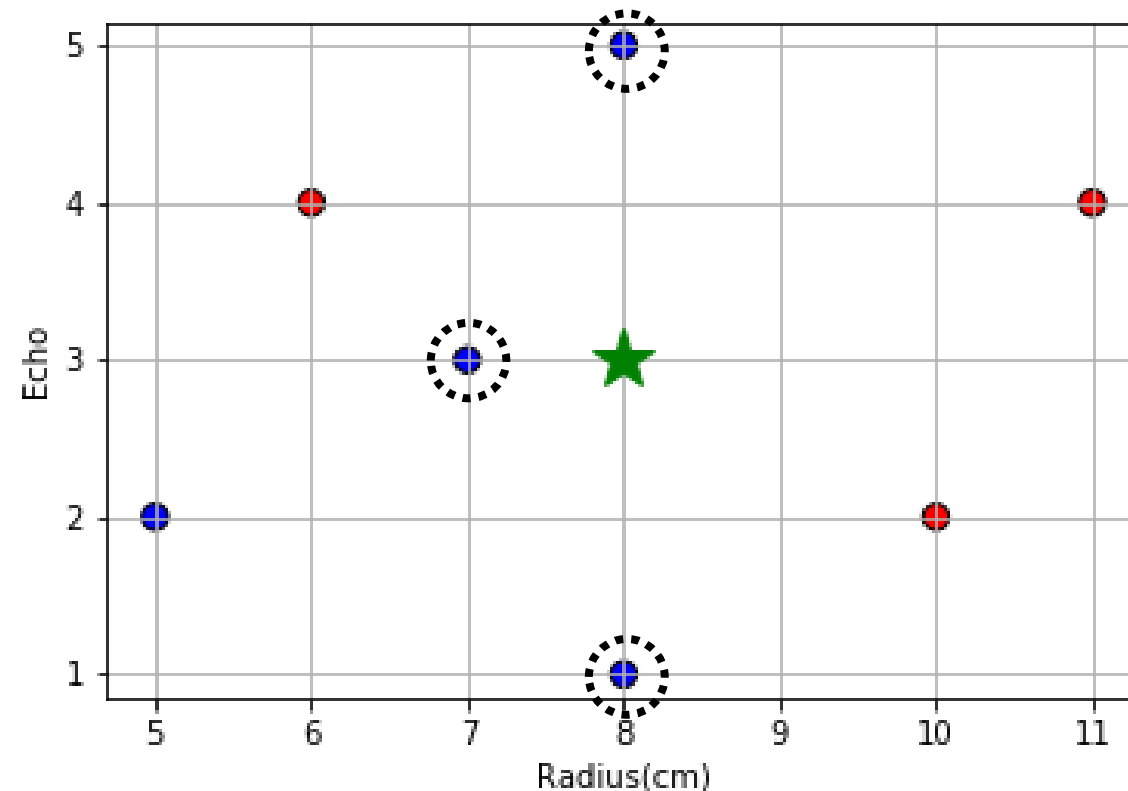
תרגיל 1 - פתרון

1. בדקו את תוצאות ה-classification עבור k-nearest neighbors, כאשר $K=1,3$.

פתרון: עבור $K=3$:

- Sweet
- Sour

$$\hat{y} = \textit{sweet}$$




תרגיל 1 - פתרון

2. בצע Cross Validation להערכת טיב המודל, עבור $K=1,3$ ו-7 קבוצות (Leave-one-out Cross Validation). באיזה מסווג נבחר?

פתרון:

$$\underbrace{(5,2)}_{X,Y} : K=1 \rightarrow \underbrace{blue}_{prediction}(random)$$

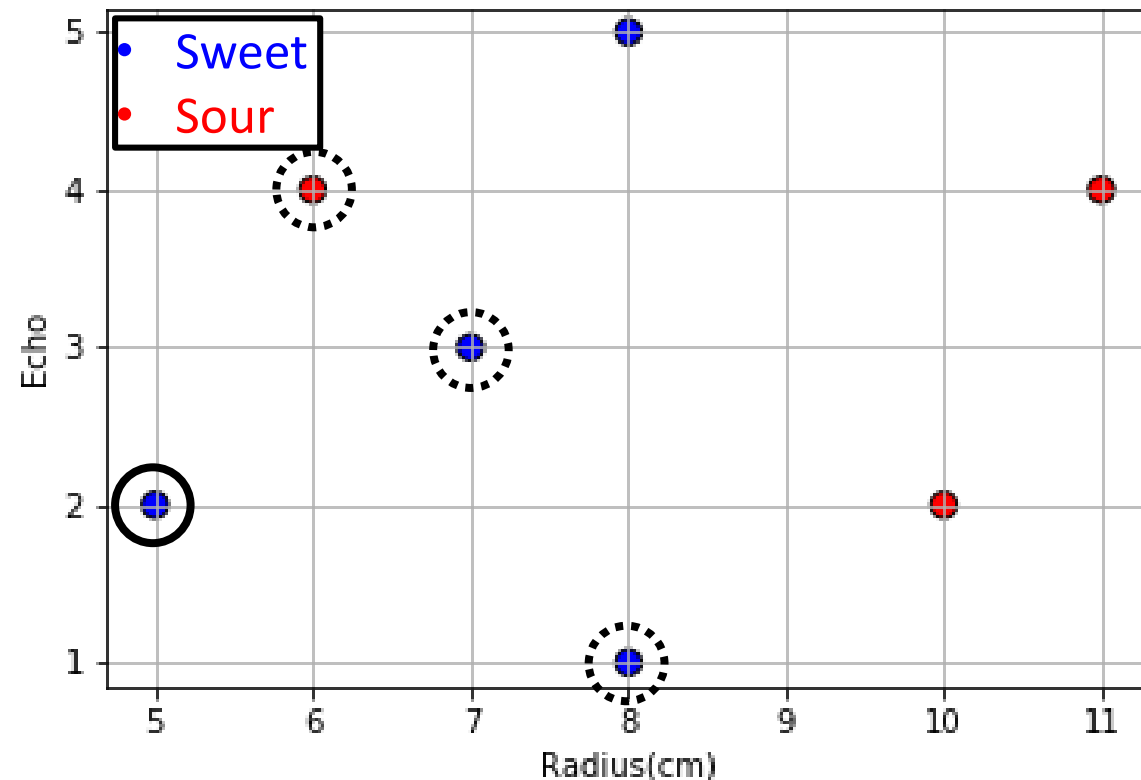


תרגיל 1 - פתרון

2. בצע Cross Validation להערכת טיב המודל, עבור $K=1,3$ ו-7 קבוצות (Leave-one-out Cross Validation). באיזה מסווג נבחר?

פתרון:

$(\underbrace{5,2}_{X,Y}, \underbrace{blue}_{prediction} : K=1 \rightarrow \underbrace{blue(random)}_{prediction}),$
 $K=3 \rightarrow \underbrace{blue}_{prediction}$



תרגיל 1 - פתרון

2. בצע Cross Validation להערכת טיב המודל, עבור $K=1,3$ ו-7 קבוצות (Leave-one-out Cross Validation). באיזה מסווג נבחר?

פתרון:

	$K = 1$	$K = 3$
$(5,2), blue$	$blue$ ✓	$blue$ ✓
$(6,4), red$	$blue$ ✗	$blue$ ✗
$(7,3), blue$	red ✗	$blue$ ✓
$(8,1), blue$	$blue$ ✓	$blue$ ✓
$(8,5), blue$	$blue$ ✓	red ✗
$(10,2), red$	$blue$ ✗	$blue$ ✗
$(11,4), red$	red ✓	$blue$ ✗

תרגיל 1 - פתרון

2. בצע Cross Validation להערכת טיב המודל, עבור $K=1,3$ ו-7 קבוצות (Leave-one-out Cross Validation). באיזה מסווג נבחר?

פתרון:

נחשב את שגיאת ה-CV:

עבור $K = 1$, מספר השגיאות הוא 3, לכן שגיאת ה-CV הינה:

$$K = 1: \hat{L}_n = \frac{3}{7}$$

עבור $K = 3$, מספר השגיאות הוא 4, לכן שגיאת ה-CV הינה:


$$K = 3: \hat{L}_n = \frac{4}{7}$$

$$\hat{L}_n = \frac{1}{k} \sum_{j=1 \dots k} \hat{L}_n^{(j)}$$


תרגיל 1 - פתרון

3. מה יקרה אם נבחר את k להיות בגודל ה- dataset.

- Sweet
- Sour



חזרה ל-KNN+Bias-Variance Tradeoff




- בשאלה זו ננסה לחזות את בחירתו של אזרח אמריקאי באמצעות אלגוריתם K-NN.
- לשם הפשטות, נניח כי כל אזרח מיוצג על ידי שני מאפיינים:
- מצבו הכלכלי (הציר האופקי - x) וקרבתו לדת (הציר האנכי - y).
- בסימונים שלמדנו:

$$x = (\text{wealth}, \text{religiousness}) \in X = \mathbb{R}_+^2$$

$$y \in \{0,1\} = \{\text{Republican}, \text{Democrat}\}$$


חזרה ל-KNN+Bias-Variance Tradeoff

ה-Dataset (מיוצג ע"י נקודות) ומשטחי ההחלטה שנובעים מאלגוריתם 1-nn:



חזרה ל-KNN+Bias-Variance Tradeoff

משטחי ההחלטה שנובעים מאלגוריתם $k=1$:



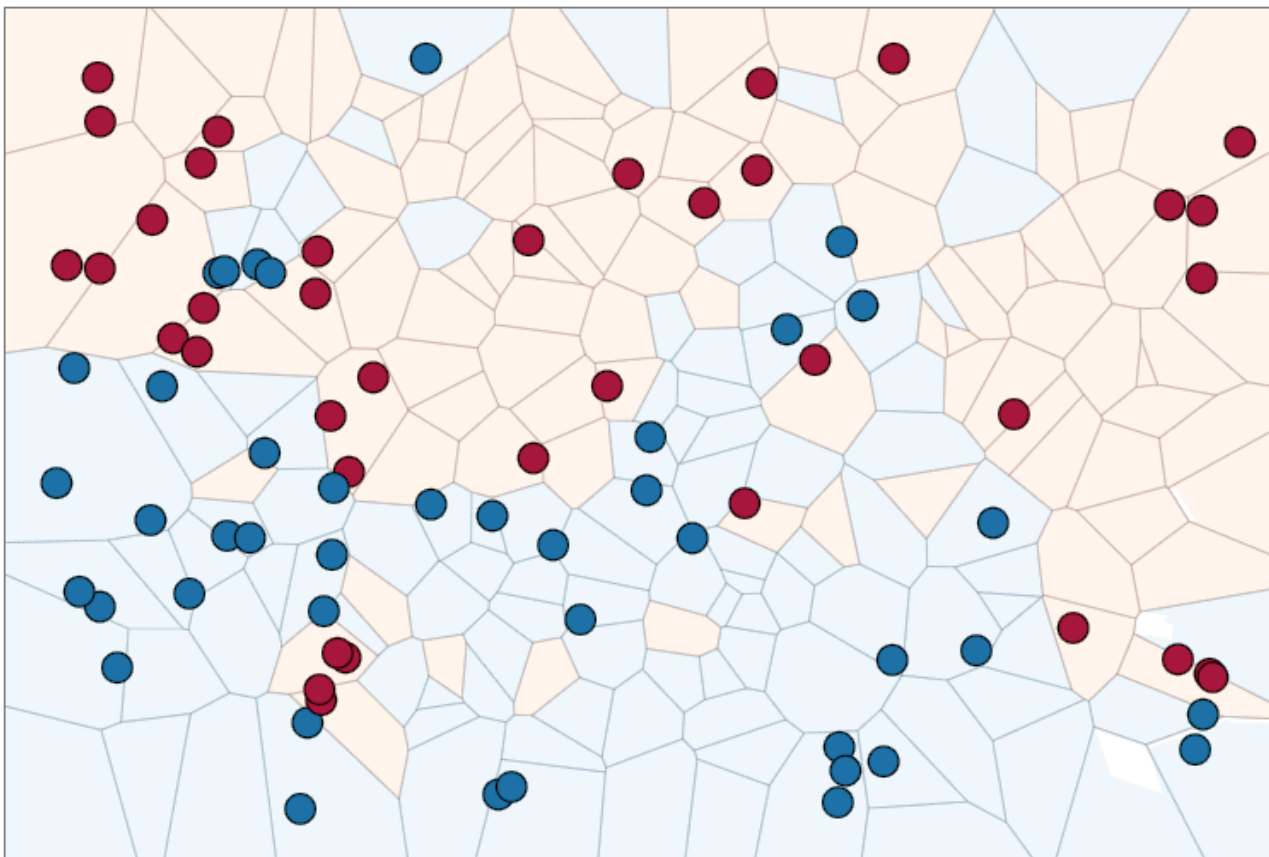
Pictures taken from:

<http://scott.fortmann-roe.com/docs/BiasVariance.html>

k -Nearest Neighbors: 1

חזרה ל-KNN+Bias-Variance Tradeoff

משטחי ההחלטה שנובעים מאלגוריתם 1-NN על סט האימון שלנו + סט בוחן
כלשהו:




Pictures taken from:

<http://scott.fortmann-roe.com/docs/BiasVariance.html>

חזרה ל-KNN+Bias-Variance Tradeoff

משטחי ההחלטה שנובעים מאלגוריתם $k=3$:




Pictures taken from:

<http://scott.fortmann-roe.com/docs/BiasVariance.html>

k -Nearest Neighbors: 3

חזרה ל-KNN+Bias-Variance Tradeoff

משטחי ההחלטה שנובעים מאלגוריתם $k=50$:




Pictures taken from:

<http://scott.fortmann-roe.com/docs/BiasVariance.html>

k -Nearest Neighbors: 50

חזרה ל-KNN+Bias-Variance Tradeoff

משטחי ההחלטה שנובעים מאלגוריתם nn-100:



Pictures taken from:


<http://scott.fortmann-roe.com/docs/BiasVariance.html>

k -Nearest Neighbors: 100

Breast Cancer Wisconsin - Dataset

שיטה נפוצה היום להבחנה של סרטן היינה בשיטת **Fine-needle aspiration**.
בשיטה זאת נלקחת דגימה של הרקמה ובעזרת מחט ומבוצעת אנליזה בעזרת
מיקרוסקופ על מנת לאבחן שני מקרים:

- רקמה סרטנית – Malignant
- רקמה לא סרטנית - Benign



מבנה ה - DataSet

- המידע מאופיין על ידי 30 ערכים נומריים כגון שטח רקמה ממוצעת.
- המידע חולץ מתוך 569 דגימות שונות.
- כל דגימה מתויגת אם הרקמה סרטנית או לא.

Dataset זה בנוי למשימת קלסיפיקציה בינארית – Binary Classification

מבנה ה - DataSet

- 10 הרשומות הראשונות (לא באופן מלא) של ה- Dataset נראות כך:

	id	diagnosis	radius_mean	texture_mean	perimeter_mean	area_mean	smoothness_mean	compactness_mean	concavity_mean	concave points_mean	...
0	842302	M	17.99	10.38	122.80	1001.0	0.11840	0.27760	0.30010	0.14710	...
1	842517	M	20.57	17.77	132.90	1326.0	0.08474	0.07864	0.08690	0.07017	...
2	84300903	M	19.69	21.25	130.00	1203.0	0.10960	0.15990	0.19740	0.12790	...
3	84348301	M	11.42	20.38	77.58	386.1	0.14250	0.28390	0.24140	0.10520	...
4	84358402	M	20.29	14.34	135.10	1297.0	0.10030	0.13280	0.19800	0.10430	...
5	843786	M	12.45	15.70	82.57	477.1	0.12780	0.17000	0.15780	0.08089	...
6	844359	M	18.25	19.98	119.60	1040.0	0.09463	0.10900	0.11270	0.07400	...
7	84458202	M	13.71	20.83	90.20	577.9	0.11890	0.16450	0.09366	0.05985	...
8	844981	M	13.00	21.82	87.50	519.8	0.12730	0.19320	0.18590	0.09353	...
9	84501001	M	12.46	24.04	83.97	475.9	0.11860	0.23960	0.22730	0.08543	...

10 rows × 32 columns

אנליזה ראשונית

לשם פשטות, רק לצורך הצגת התוצאות נבחן את שני המאפיינים הבאים
: (features)

- **Radius_mean** – הרדיוס הממוצע של התאים בדגימה.

- **Texture_mean** – סטיית תקן הממוצעת של רמות האפור של התאים בדגימה.


$$x_i = \{\text{Radius_mean}, \text{Texture_mean}\}$$

והתיוג - y_i :



- **Diagnosis** – מציין את התיוג, האם הרקמה סרטנית.

הערה: בפועל מבצעים לימוד על כל המאפיינים.


מספר התאים הסרטניים והלא סרטניים



ההתפלגות של המאפיינים



ההתפלגות של המאפיינים



הערכת ביצועים וחלוקת הdata

• Misclassification Rate:

$$R\{h, \{x, y\}\} = \frac{1}{N} \sum_i I\{h(x_i) \neq y_i\}$$

• נחלק את ה Dataset לשניים


• Train set שהיינו 80% מכלל ה Dataset

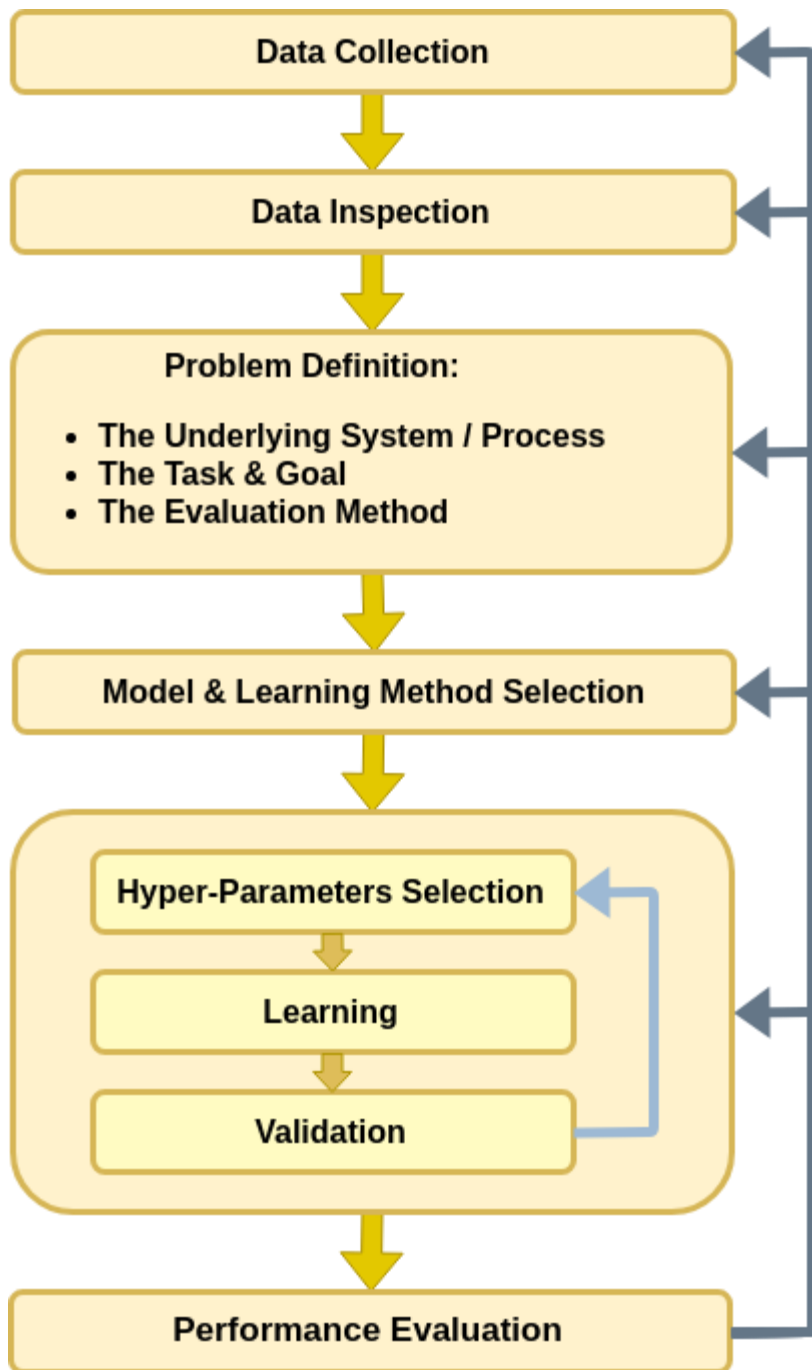
• Test set שהיינו 20% מכלל ה Dataset

Model: 1-NN

נאמן את המודל השכן הקרוב ונציג את אזורי ההחלטה באמצעות פונקציית Voroni מחבילת SciPy.

הערכת ביצועים:
Test set risk: 0.14





שיפור ביצועים

מה ניתן לעשות על מנת לשפר ביצועים?

- ניתן לשנות את ההיפר-פרמטרים, כלומר את משפר בשכנים - K .

שיטות לכיוון היפר-פרמטרים:


Brute Force / Grid Search •

ניסוי וטעיה •

Cross-validation •

Grid Search

הערכת ביצועים:
Test set risk: 0.061
 $K = 12$



Train-Validation-Test split / 3-fold split

על מנת להימנע מהתאמת ייתר (over fitting) נחלץ מתוך dataset מקטע לוולידציה.


נהוג לחלק ל:

- 60% train set
- 20% validation set
- 20% test set

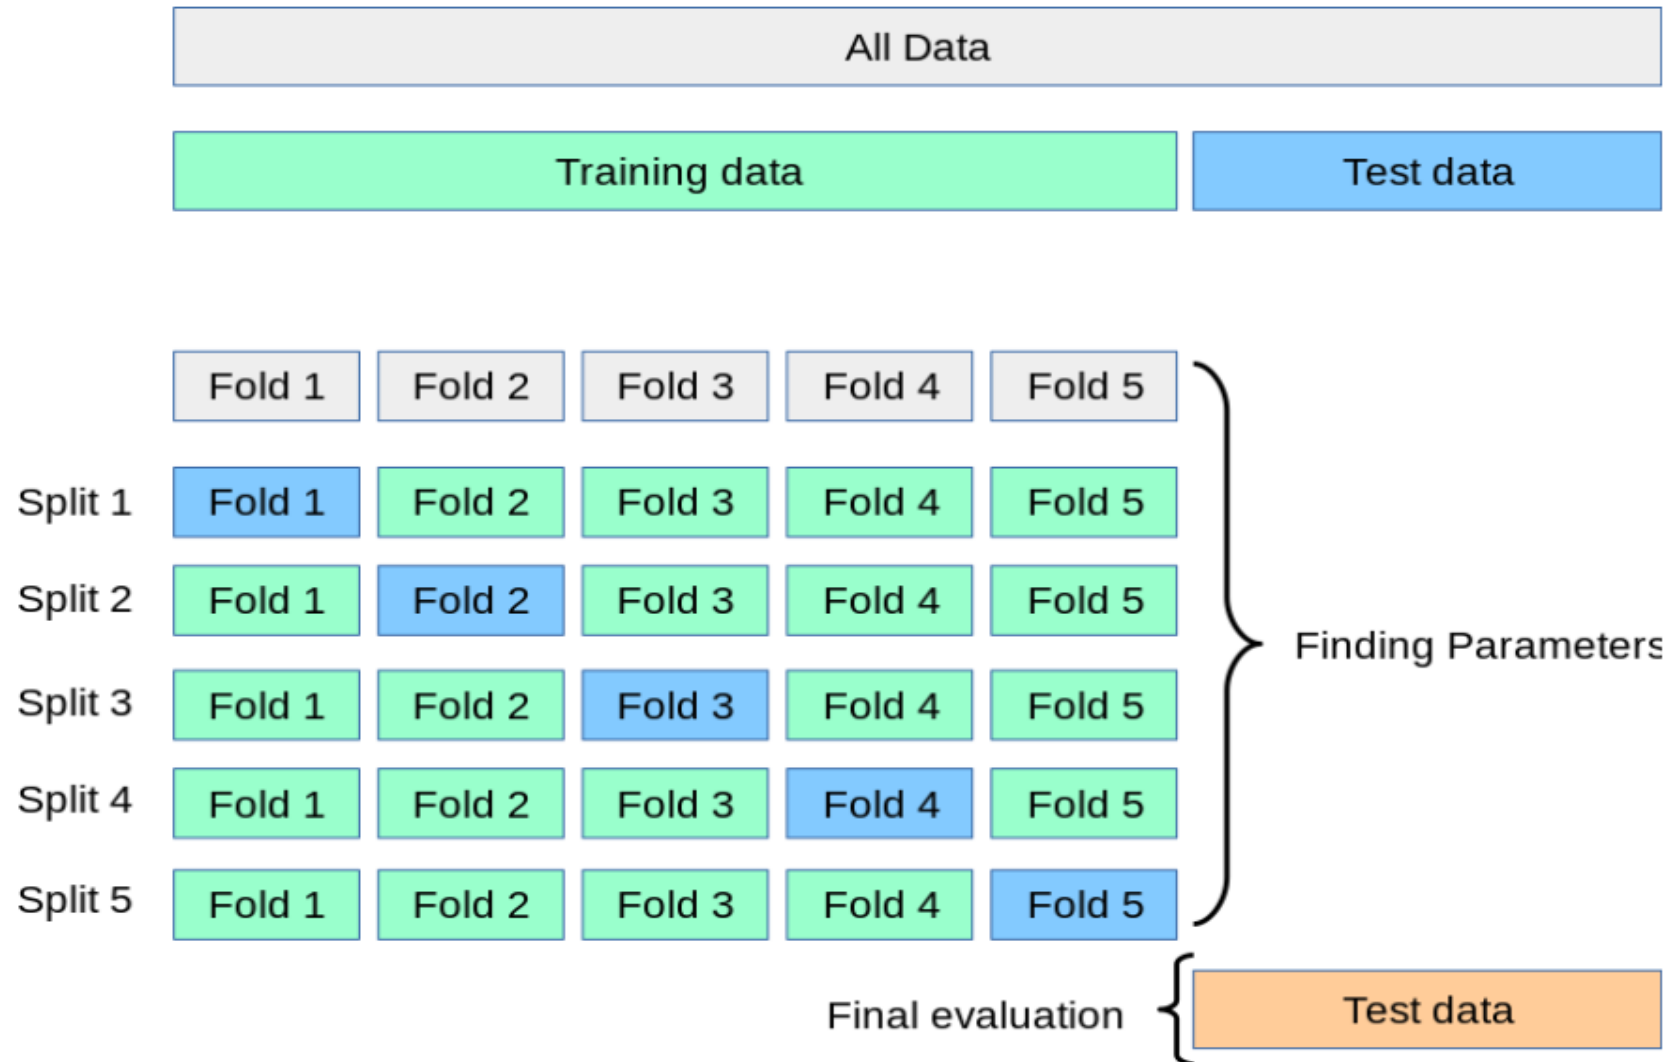
הערה: ביצוע כיוון פרמטרים על test set מוביל לover fitting, והערכת ביצועים מוטעית

3-fold split

הערכת ביצועים:
Test set risk: 0.097
 $K = 19$



Cross Validation



Cross Validation

הערכת ביצועים:
Test set risk: 0.079
 $K = 22$

